

LLM agents có phải là “silicon samples” hợp lệ?

cho hành vi hợp tác của con người

Hai thí nghiệm hợp tác kinh điển

rủi ro khí hậu (Milinski 2008) • trừng phạt public-goods (Herrmann 2008)

Nội dung báo cáo

1. **Bối cảnh & câu hỏi chung** — LLM làm "silicon samples" & tiêu chí *behavioural validity*
2. **Paper A — Collective-risk climate dilemma** (rủi ro thảm họa)
3. **Paper B — Public-goods game với trừng phạt** (antisocial punishment)
4. **Tổng hợp & Kết luận** — một tiêu chí, hai dissociation

Thông điệp một câu

Cả 2 paper cho cùng kết luận: LLM agents tái tạo **bề mặt** của hợp tác, nhưng **đánh mất cấu trúc chẩn đoán** làm nên ý nghĩa khoa học của thí nghiệm.

Hai paper đồng hành (companion), dùng chung framework, model và tiêu chí đánh giá.

Phần 1

Bối cảnh & Câu hỏi chung

LLM làm “silicon samples” thay người

- LLM ngày càng được dùng làm **người chơi nhân tạo** trong economic games (“homo silicus”, “generative agents”).
- Hứa hẹn: **re, nhanh, mở rộng được** — pilot cho thiết kế thí nghiệm, mô phỏng dân số khó tuyển.
- Có báo cáo: phản hồi LLM vượt qua “Turing test hành vi”.

Tiền đề then chốt: *behavioural validity*

LLM chỉ hữu ích nếu tái tạo **cách hành vi người phản ứng** với đòn bẩy thí nghiệm — không chỉ mức trung bình.

2 papers · LLM agents

Behavioural validity của LLM trong trò chơi hợp tác



Argyle 2023; Horton 2023; Park 2023; Aher 2023; Mei 2024

Tiêu chí hợp lệ: phản ứng, không phải mức trung bình

Luận điểm thống nhất của 2 paper

Một surrogate hợp lệ phải tái tạo **phản ứng với biến thao tác / cấu trúc quan hệ**
— *không phải mức* hành vi trung bình mà nó thể hiện.

Paper A — CRSD (Climate)

- Biến chẩn đoán: **loss probability** p .
- Test: hợp tác có *giảm* khi rủi ro giảm như ở người không?

Paper B — PGG (Punishment)

- 2 chữ ký chẩn đoán:
 - **trừng phạt có nâng hợp tác?**
 - **cấu trúc xuyên văn hóa** của antisocial punishment.

Cùng kiểm chứng một câu hỏi: LLM có *cơ chế* của con người, hay chỉ *bề mặt*?

Phương pháp chung (cả 2 paper)

- Mỗi agent nhận 1 prompt: **luật chơi + lịch sử + disposition/society**, rồi xuất dòng quyết định parse được (CONTRIBUTION = X...).
- Quyết định thu theo **lô đồng bộ** mỗi vòng $\Rightarrow$ thật sự đồng thời.
- **3 open models** (vLLM, *temp* 0.8, seed cố định, offline RTX PRO 6000):
 - Qwen2.5-7B · Gemma-2-9B · Llama-3.1-8B
- **Replication trung thành** các thí nghiệm người kinh điển.

Thiết kế giai thừa

- **5 ngôn ngữ**: EN · FR · AR · ZH · VI
- **4 disposition**: neutral, cooperative, selfish, **risk-averse/vengeful**
- **10 nhóm độc lập / điều kiện**
- Paper B: +**16 society personas** (TP của Herrmann)

Framework: **FAIRGAME**. Benchmark người: Milinski 2008 & Herrmann 2008.

Phần 2


Paper A — Collective-risk climate dilemma

Paper A — Trò chơi CRSD (Milinski 2008)

- 6 người chơi, mỗi người vốn €40, chơi 10 vòng.
- Mỗi vòng góp €0 / €2 / €4 vào "quỹ khí hậu".
- Mục tiêu nhóm: tích lũy €120; không đạt $\Rightarrow$ **xổ sổ**: x.suất p mọi người **mất sạch**.
- Biến chuẩn đoán: $p \in \{90\%, 50\%, 10\%\}$; tối đa €240.

Chữ ký ở con người

p giảm $\Rightarrow$ đầu tư **giảm mạnh** (€118 $\rightarrow$ 92 $\rightarrow$ 73; ANOVA $F = 13.78$).



Milinski et al. 2008, PNAS


A1 — Over-cooperation ở mọi mức rủi ro

Người chơi	$p = 90\%$	$p = 50\%$	$p = 10\%$
Con người (Milinski)	118.2 (50%)	92.2 (10%)	73.0 (0%)
Qwen2.5-7B	183.0 (100%)	186.6 (100%)	181.0 (100%)
Gemma-2-9B	168.2 (100%)	162.8 (100%)	158.0 (100%)
Llama-3.1-8B	177.4 (100%)	165.2 (100%)	170.0 (100%)

Final group total € (tỉ lệ đạt target). Target = €120; tối đa khả thi = €240.

- Cả 3 model đạt target **100% mọi mức risk**.
- Đầu tư **€158–187** ($\approx 66\text{--}78\%$ trên €240).
- $\sim 6/6$ fair-sharers vs 1–3 ở người.
- Mọi contrast LLM–người đều **significant**.


A2 (QUYẾT ĐỊNH) — Vô cảm với rủi ro thảm họa



Người giảm dốc khi rủi ro giảm — cả 3 model gần như **PHẪNG**, đều vượt €120.

ANOVA F : 13.78 (người) vs 1.76 / 2.23 / 3.64 • TOST $p \leq .014$ • BF_{01} 4.8 / 3.0 (Llama equivocal)

A3 — Hợp tác là “núm vặn”, bất biến ngôn ngữ



Đổi 1 câu disposition: selfish → 0% thành công. Nội dung bất biến qua 5 ngôn ngữ.

Selfish 0% (Qwen,Gemma) / 27% (Llama) • risk-averse 73–93% • parse-fallback Gemma/AR 13.7%,
Llama/VI 14.8% (EN ≈0%)

Chân dung

Risk-insensitive · prompt-steerable · over-cooperator

- Tái tạo **bề mặt** của hành động khí hậu hợp tác (đạt target, chia sẻ gánh nặng)...
- ...nhưng **thiếu cơ chế** kết nối với rủi ro thảm họa — thứ tạo ra & điều biến hành động đó ở người.
- Manipulation làm thí nghiệm *có ý nghĩa* lại gần như **không tác động** lên model.

Phản biện trước (self-summation): agent không được xem tổng tích lũy, nhưng gánh nặng số học *không đổi* giữa các mức risk $\Rightarrow$ không giải thích được vì sao hành vi không khác nhau *giữa* các mức rủi ro.

Phần 3

Paper B — Public-goods game với trừng phạt

Paper B — PGG với trừng phạt (Herrmann 2008)

- 4 người chơi (partner), 10 vòng; mỗi vòng nhận 20 token.
- Góp vào quỹ chung, $MPCR = 0.4$ (mỗi token góp $\rightarrow 0.4$ cho cả 4).
- 2 treatment: N (chỉ góp) vs P (thêm trừng phạt tổn kém).
 - Trả 1 token để trừ 3 token của người khác (tỉ lệ 1:3).
- Phân loại: trừng phạt người góp ít hơn = **prosocial**; góp bằng/nhiều hơn = **antisocial**.

2 chữ ký chẩn đoán ở người

1. Trừng phạt **NÂNG** hợp tác (P–N $\approx +4.3$ token).
2. **Cấu trúc xuyên văn hóa**: antisocial punishment $\leftrightarrow$ hợp tác có $\rho \approx -0.90$ qua 16 xã hội.

16 personas thành phố trung lập (Boston...Riyadh, Athens), không gán định kiến hành vi.


B1 — Góp hào phóng & trừng phạt, nhưng đa số là antisocial

Người chơi	Góp N	Góp P	Δ (P–N)	% antisocial
Con người (Herrmann)	8.6	12.9	+4.3	thiếu số*
Qwen2.5-7B	14.26	13.90	−0.36 ($p=.71$)	59%
Gemma-2-9B	13.41	9.86	−3.55 ($p<.001$)	55%
Llama-3.1-8B	10.67	10.75	+0.08 ($p=.91$)	54%

Đóng góp trung bình /20 token. *Ở người: antisocial là thiếu số ở pool phương Tây, nhưng cao ở một số xã hội khác — chính là biến thiên xuyên văn hóa.

- Baseline N: cả 3 model **trên mức người** (8.6); model **có** góp & **có** trừng phạt.
- Nhưng **54–59%** điểm trừng phạt là **antisocial** — nhắm vào người góp *bằng hoặc hơn* — ngang pool người trừng phạt nặng nhất.

B2 (QUYẾT ĐỊNH) — Trừng phạt KHÔNG nâng hợp tác




Đường P nằm DƯỚI N — trừng phạt không nâng (Gemma còn giảm), ngược hẳn người.

$P-N = -0.36 / -3.55 / +0.08$ vs người $+4.3^\dagger$ • TOST $p = .010/.002$ • BF_{01} 2.3/2.5

† mức tăng $+4.3$ của người là *within-subject* (agent chơi N, P ở nhóm độc lập); (b) chỉ Gemma giữ gradient.

B3 — Cấu trúc xuyên văn hóa sụp đổ



Liên kết antisocial-hợp tác $\rho \approx -0.90$ ở người $\rightarrow$ gần BẰNG 0 ở model; “geography” biến mất.

$\rho = -0.09 / -0.15 / +0.30$ (người -0.90 ; Fisher- z $p \leq .0011$) • rank ρ vs người $+0.33 / +0.06 / +0.17$
2 papers • LLM agents Behavioural validity của LLM trong trò chơi hợp tác

Dissociation

Tái tạo **sự tồn tại** của (anti)social punishment
— nhưng **không** chức năng thể chế, **không** cấu trúc văn hóa

- Marginals trông “giống người” (kể cả antisocial punishment cao bất ngờ)...
- ...nhưng 2 thuộc tính **quan hệ** làm nên giá trị khoa học đều biến mất: **trừng phạt** → **hợp tác**, và **biến thiên xuyên văn hóa**.
- Trao quyền trừng phạt cho agent có thể thành **gánh nặng**, không phải lá chắn cho hợp tác.

Phần 4

Tổng hợp & Kết luận

Một tiêu chí, hai dissociation song song

	Bề mặt được tái tạo	Cấu trúc chẩn đoán bị mất
Paper A CRSD / Climate	Hợp tác cao, đạt target 100%	Phản ứng với <i>loss probability</i> (vô cảm rủi ro)
Paper B PGG / Punishment	Góp hào phóng + trừng phạt (54–59% antisocial)	(i) trừng phạt nâng hợp tác; (ii) cấu trúc xuyên văn hóa

Mẫu hình chung

"Cooperation is **real as output**, **absent as mechanism**." — bề mặt giống người *không* bảo chứng cho cơ chế giống người.

Tiêu chí “behavioural validity” (đóng góp lý thuyết)

- Test một “silicon subject” **không phải** bằng *mức* hành vi trung bình...
- ...mà bằng **phản ứng với biến thao tác & cấu trúc quan hệ/điều kiện**.
- Nghiên cứu chỉ đọc *marginals* sẽ kết luận **sai** rằng agent “tái tạo” được kết quả người.
- Hành vi bị chi phối bởi **prompt** (model được bảo *là ai*), không phải **incentive** của game.

Hệ quả

- **Computational social science**: validate trên chữ ký chẩn đoán, không phải vẽ ngoài hợp lý.
- **Multi-agent LLM systems**: thể chế trừng phạt của con người **không tự động chuyển giao**.
- Dùng agent mô phỏng đàm phán/chính sách → dễ **dự báo sai** comparative statics.

Hạn chế (chung cho cả 2 paper)

- **Phạm vi model:** 3 open model 7–9B, 1 temperature $\Rightarrow$ chưa kết luận cho model lớn/frontier.
- **Confound thiết kế:** CRSD không hiển thị tổng tích lũy (self-summation); PGG so sánh between-group còn người là within-subject.
- **Cross-language confound:** parse-fallback không đồng đều (PGG: Gemma/AR tới 31–43%) $\Rightarrow$ một số ô mẫu nhỏ hơn.
- **Persona tối giản** (PGG): chỉ nhãn thành phố, chưa test persona giàu chuẩn mực.
- **Prompt-sensitive & alignment training:** nhiều khả năng thổi phồng hợp tác và làm phẳng trừng phạt.

Kết luận





- Hai thí nghiệm hợp tác kinh điển, cùng một kết luận: open LLM agents tái tạo **bề mặt** nhưng **mất cấu trúc chuẩn đoán**.
- **CRSD**: hợp tác cao nhưng **vô cảm với rủi ro thảm họa**.
- **PGG**: trừng phạt tồn tại (đa phần antisocial) nhưng **không nâng hợp tác, không cấu trúc văn hóa**.
- Test validity đúng = **phản ứng với manipulation**; trên đó, agent **chưa thay thế được con người**.

Hướng tiếp theo

- Model frontier: chữ ký chuẩn đoán có hồi phục theo scale?
- Persona giàu chuẩn mực; cho phép giao tiếp & reciprocity.
- Tách risk-response khỏi running-total (CRSD).
- Agent huấn luyện bằng RL trong chính game.

Cảm ơn Thầy — rất mong nhận góp ý!

Phụ lục — Human vs LLM: căn chỉnh trực tiếp (PGG)



4 góc nhìn so sánh người (đen) vs 3 model:

- **Conditional punishment:** chỉ Gemma bám hình dạng người.
- **Contribution trajectories:** model giữ/giảm, không có cú nâng nhờ punishment.
- **City alignment:** điểm model nằm lệch khỏi đường chéo (không khớp người).
- **Next-period reaction:** phản ứng với điểm bị phạt khác người.